
Guide de préparation

Soutenance Bloc 1 et 2

Titre RNCP40875 – Expert en Ingénierie des données

Mastère 1 Data Engineering & IA

Certificateur : Efrei

Session 2026-2027

1. OBJECTIF DE LA SOUTENANCE

Cette soutenance a pour objectif de démontrer que vous maîtrisez les compétences des Blocs 1 et 2 de la certification Expert en ingénierie des données.

Elle s'appuie sur les trois projets formatifs réalisés pendant la formation :

1. **Projet 1 — Architecture de données** : Validation des compétences du Bloc 1 : construire, superviser et développer une architecture de données.
2. **Projet 2 — Data Science** : Validation des compétences du Bloc 2 liées à la préparation des données, l'analyse, la visualisation, le machine learning et la stratégie d'intégration de l'IA.
3. **Projet 3 — IA générative** : Validation des compétences du Bloc 2 liées à l'identification, au développement et à l'évaluation d'une solution d'IA générative.

La soutenance ne consiste pas à raconter tous les projets dans le détail. Elle consiste à prouver vos compétences à partir de réalisations concrètes, de choix justifiés et de résultats démontrables.

2. FORMAT DE LA SOUTENANCE

Durée : 50 minutes

- Présentation/démonstration : 30 minutes
- Échange avec le jury : 20 minutes

La présentation est collective, mais l'évaluation reste individualisée. Chaque étudiant doit donc être capable d'expliquer sa contribution personnelle, ses choix, ses difficultés et les compétences qu'il a mobilisées.

3. LOGIQUE GENERALE ATTENDUE

Votre présentation doit suivre une logique professionnelle :

Besoin métier → choix techniques → réalisation → preuve → résultat → limites et améliorations

Vous devez éviter une présentation purement descriptive. Il faut plutôt montrer : "Nous avons répondu à tel besoin par tel choix technique, parce que..., et nous pouvons le démontrer par..."

4. STRUCTURE RECOMMANDEE DE LA PRESENTATION — 30 MINUTES

⇒ **Recommandation de déroulé :**

1. Introduction générale : 2 minutes
2. Projet 1 — Architecture de données / Bloc 1 : 9 minutes
3. Projet 2 — Data Science / Bloc 2 : 9 minutes
4. Projet 3 — IA générative / Bloc 2 : 6 minutes
5. Conclusion transversale : 4 minutes

4.1 PARTIE 1 — INTRODUCTION GENERALE

⇒ **Durée : 2 minutes**

L'introduction doit permettre au jury de comprendre rapidement le contexte des trois projets.

⇒ **À présenter**

- le contexte métier ou le cas d'usage global ;
- les objectifs des trois projets ;
- les blocs de compétences évalués ;
- la répartition des rôles dans le groupe.

⇒ **Exemple de formulation**

« Notre soutenance vise à démontrer les compétences des Blocs 1 et 2 à travers trois projets complémentaires : un projet d'architecture de données, un projet Data Science et un projet d'IA générative. Ensemble, ces projets couvrent la conception d'une architecture de données, l'exploitation analytique et prédictive des données, ainsi que la mise en œuvre d'une solution fondée sur l'IA générative. »

4.2. PARTIE 2 — PROJET 1 : ARCHITECTURE DE DONNEES

⇒ **Bloc 1 — Durée : 9 minutes**

Cette partie doit démontrer les compétences du **Bloc 1 : construire, superviser et développer une architecture de données**.

Le référentiel attend notamment une solution comprenant une base relationnelle, une base non relationnelle, un Data Lake, un système distribué, des pipelines optimisés et une infrastructure scalable et résiliente.

⇒ **Compétences à démontrer**

Compétence	Ce que vous devez démontrer
C1.1	Conception et développement d'une base relationnelle adaptée au besoin
C1.2	Conception et développement d'une base non relationnelle adaptée
C1.3	Construction d'un Data Lake sécurisé intégrant des sources variées
C1.4	Architecture scalable et résiliente
C2.1	Création d'une API interopérable et sécurisée
C2.2	Mise en œuvre d'un système distribué ou de streaming
C2.3	Transformation et intégration de données multi-sources
C2.4	Optimisation des pipelines et mesure de la performance

⇒ **Structure conseillée pour cette partie :**

1. Besoin métier ou besoin de gouvernance
2. Architecture proposée
3. Choix techniques
4. Preuves techniques
5. Résultats et limites

⇒ **À éviter :**

- Détailler chaque ligne de code ;
- Passer trop de temps sur l'installation technique ;
- Présenter les outils sans les relier aux compétences ;
- Oublier la sécurité, la performance ou la scalabilité.

4.3. PARTIE 3 — PROJET 2 : DATA SCIENCE

⇒ **Bloc 2 — Durée : 9 minutes**

Cette partie doit démontrer les compétences du Bloc 2 liées à la préparation des données, l'analyse exploratoire, la visualisation, le machine learning et la stratégie d'intégration de l'IA.

⇒ **Compétences à démontrer**

Compétence	Ce que vous devez démontrer
C3.1	Préparation, nettoyage, transformation et qualité des données
C3.2	Tableau de bord interactif, clair, inclusif et utile à la décision
C3.3	Analyse exploratoire et production d'insights exploitables
C4.1	Stratégie d'intégration de l'IA dans un processus métier
C4.2	Développement d'un modèle prédictif fonctionnel
C4.3	Évaluation comparative de plusieurs modèles avec métriques adaptées

⇒ **Structure conseillée pour cette partie :**

1. Question métier
2. Préparation et nettoyage
3. Analyse exploratoire
4. Modélisation prédictive
5. Comparaison et écoresponsabilité

⇒ **Preuves à préparer :**

- extrait du dataset avant/après nettoyage ;
- notebook ou pipeline de préparation ;
- graphiques d'analyse exploratoire ;
- dashboard ;
- tableau comparatif des modèles ;
- matrice de confusion, score, courbe ou métrique adaptée ;
- justification du modèle final.

⇒ **À éviter :**

- présenter uniquement les scores sans expliquer leur sens ;
- oublier la question métier ;

- confondre corrélation et causalité ;
- ne présenter qu'un seul modèle ;
- ne pas expliquer les limites du modèle.

4.4. PARTIE 4 — PROJET 3 : IA GENERATIVE

⇒ **Bloc 2 — Durée : 6 minutes**

Cette partie doit démontrer les compétences liées à l'IA générative : identification d'un cas d'usage, développement d'une solution et évaluation des résultats générés.

⇒ **Compétences à démontrer :**

Compétence	Ce que vous devez démontrer
C5.1	Identification d'un cas d'usage GenAI pertinent pour le métier
C5.2	Développement d'une solution GenAI adaptée, fonctionnelle et accessible
C5.3	Évaluation des résultats générés et ajustement des paramètres

⇒ **Structure conseillée pour cette partie :**

- Cas d'usage
- Choix du modèle ou de l'approche
- Solution développée
- Évaluation des résultats
- Valeur métier

⇒ **Preuves à préparer :**

- exemple de prompt ou de scénario d'usage ;
- capture de la solution ;
- exemple d'entrée/sortie ;
- grille d'évaluation des réponses générées ;
- comparaison avant/après ajustement ;
- limites et risques identifiés.

⇒ **À éviter :**

- dire simplement "nous avons utilisé ChatGPT" ou "nous avons utilisé un LLM" ;
- ne pas justifier le cas d'usage ;
- ne pas évaluer la qualité des résultats ;
- oublier les limites, les biais ou les risques ;
- présenter une démonstration sans lien avec un besoin métier.

4.5. PARTIE 5 — CONCLUSION TRANSVERSALE

⇒ **Durée : 4 minutes**

La conclusion doit permettre de montrer que les trois projets constituent des preuves complémentaires de maîtrise des compétences attendues aux Blocs 1 et 2.

⇒ **À présenter :**

- les compétences du Bloc 1 démontrées par le projet **Architecture de données** ;
- les compétences du Bloc 2 démontrées par le projet **Data Science** ;
- les compétences du Bloc 2 démontrées par le projet **IA générative** ;
- les principales preuves apportées ;
- les résultats obtenus ;
- les limites et améliorations possibles ;
- les apprentissages professionnels tirés des projets ;
- les contributions individuelles.

⇒ **Exemple de formulation**

« À travers ces trois projets, nous avons pu démontrer les compétences attendues pour les Blocs 1 et 2. Le projet Architecture de données nous a permis de concevoir, développer et superviser une architecture adaptée à des besoins de stockage, d'intégration, d'accès et de transformation des données. Le projet Data Science nous a permis de préparer les données, de produire des analyses exploitables, de construire des visualisations utiles à la décision et de comparer plusieurs modèles prédictifs. Le projet IA générative nous a permis d'identifier un cas d'usage pertinent, de développer une solution adaptée et d'évaluer la qualité des résultats générés. Ces réalisations nous ont conduits à justifier nos choix, à produire des preuves concrètes, à analyser les résultats obtenus et à identifier des pistes d'amélioration dans une logique professionnelle. »

4.6. ORGANISATION DES 20 MINUTES D'ÉCHANGE AVEC LE JURY

Les 20 minutes d'échange permettent au jury de vérifier la maîtrise réelle des compétences. Il faut s'attendre à quatre types de questions :

Bloc	Exemples de Questions
Bloc 1 — Architecture de données	• Pourquoi avoir choisi cette base relationnelle ? • Comment avez-vous garanti l'intégrité des données ? • Pourquoi avoir utilisé une base NoSQL ? • Comment le Data Lake intègre-t-il des sources variées ? • Quelles contraintes de sécurité avez-vous prises en compte ? • Comment l'architecture est-elle scalable ? • Comment avez-vous testé la résilience ? • Comment fonctionne votre API ? • Quels mécanismes d'authentification ou d'autorisation avez-vous prévus ? • Comment mesurez-vous la performance des pipelines ?
Bloc 2 – Projet Data Science	• Quelles données avez-vous utilisées ? • Quels problèmes de qualité avez-vous identifiés ? • Comment avez-vous traité les valeurs manquantes ? • Pourquoi avoir choisi ces variables ? • Quels insights ressortent de l'analyse exploratoire ? • À qui s'adresse votre tableau de bord ? • En quoi votre dashboard aide-t-il à la décision ? • Quels modèles avez-vous testés ? • Pourquoi avoir retenu ce modèle final ?

	• Quelles métriques avez-vous utilisées ? • Comment avez-vous évité le surapprentissage ? • Quelles limites présente votre modèle ?
Bloc 2 – Projet IA générative	• Pourquoi ce cas d’usage est-il pertinent ? • Pourquoi l’IA générative est-elle adaptée ici ? • Quel modèle ou quelle approche avez-vous utilisé ? • Comment avez-vous évalué la qualité des réponses ? • Quels paramètres avez-vous ajustés ? • Quels risques avez-vous identifiés ? • Comment prenez-vous en compte l’accessibilité ? • Quelles limites voyez-vous à votre solution ? • Comment pourriez-vous l’industrialiser ?

⇒ 10.4 Questions d’individualisation

Même si la présentation est collective, chaque étudiant doit avoir un rôle visible. Chaque étudiant doit cependant pouvoir répondre à des questions sur l’ensemble du projet, même s’il n’a pas présenté toutes les parties.

Exemples :

- Quelle a été votre contribution principale ?
- Quelle compétence pensez-vous avoir le mieux démontrée ?
- Quel choix technique avez-vous porté ?
- Quelle difficulté avez-vous rencontrée ?
- Comment l’avez-vous résolue ?
- Que referiez-vous différemment ?
- Quelle partie du projet maîtrisez-vous le mieux ?
- Quelle amélioration proposeriez-vous ?

5. CONSEILS POUR CONSTRUIRE LE SUPPORT DE PRESENTATION

Pour 30 minutes, il est conseillé de ne pas dépasser 20 slides.

⇒ Structure recommandée du diaporama

Slides	Contenu
1	Titre, noms, blocs évalués
2	Contexte métier et problématique
3	Vue d’ensemble des trois projets
4	Répartition des contributions individuelles
5 à 9	Projet 1 — Architecture de données
10 à 14	Projet 2 — Data Science
15 à 17	Projet 3 — IA générative

18	Synthèse des compétences démontrées
19	Limites et améliorations
20	Conclusion

6. GRILLE D'AUTO-VERIFICATION AVANT LA SOUTENANCE

Pour se préparer à la soutenance, chaque groupe est invité à s'auto-évaluer via les questions ci-dessous.

⇒ Bloc 1 — Architecture de données

Question	Oui / Non
Avons-nous présenté une base relationnelle adaptée au besoin ?	
Avons-nous justifié les choix SQL / NoSQL ?	
Avons-nous présenté un Data Lake ou une organisation de stockage adaptée ?	
Avons-nous expliqué la sécurité et les accès ?	
Avons-nous montré une API ou un mécanisme d'accès aux données ?	
Avons-nous présenté les pipelines de transformation ?	
Avons-nous parlé de performance, scalabilité ou résilience ?	
Avons-nous préparé des preuves techniques ?	

⇒ Bloc 2 — Data Science et IA

Question	Oui / Non
Avons-nous expliqué la préparation des données ?	
Avons-nous présenté des insights issus de l'analyse exploratoire ?	
Avons-nous montré un tableau de bord utile à la décision ?	
Avons-nous développé un modèle prédictif ?	
Avons-nous comparé plusieurs modèles ?	
Avons-nous justifié le modèle retenu ?	
Avons-nous identifié les limites du modèle ?	
Avons-nous présenté une stratégie d'intégration de l'IA ?	

⇒ Bloc 2 — IA générative

Question	Oui / Non
Avons-nous identifié un cas d'usage GenAI pertinent ?	
Avons-nous justifié le choix du modèle ou de l'approche ?	
Avons-nous présenté une solution fonctionnelle ?	
Avons-nous évalué la qualité des résultats générés ?	
Avons-nous expliqué les ajustements réalisés ?	
Avons-nous identifié les limites et risques ?	

⇒ **Individualisation**

Question	Oui / Non
Chaque étudiant connaît-il sa contribution personnelle ?	
Chaque étudiant sait-il expliquer au moins un choix technique ?	
Chaque étudiant peut-il citer les compétences qu'il démontre ?	
Chaque étudiant peut-il répondre à une question sur les limites du projet ?	

7. ERREURS FREQUENTES A EVITER

- ⇒ **Erreur 1 - Présenter les projets sans lien avec les compétences :** Le jury n'évalue pas seulement le projet. Il évalue les compétences. Il faut donc clairement relier la démonstration aux compétences. Ex : « Cette partie démontre la compétence C1.3 car... »
- ⇒ **Erreur 2 - Montrer des résultats sans justification :** Un bon résultat ne suffit pas. Il faut expliquer :
 - pourquoi ce choix ;
 - pourquoi cette méthode ;
 - pourquoi cette métrique ;
 - pourquoi ce modèle ;
 - pourquoi cette architecture.
- ⇒ **Erreur 3 - Oublier les limites :** Reconnaître une limite n'est pas un échec. C'est une preuve de recul professionnel.
- ⇒ **Erreur 4 - Faire une démonstration trop longue :** La démonstration doit être courte, maîtrisée et utile. Elle doit servir la preuve de compétence.
- ⇒ **Erreur 5 - Ne pas préparer l'individualisation :** Chaque étudiant doit être capable de répondre personnellement. Une réponse collective ne suffit pas toujours.

8. CONCLUSION

La soutenance n'est pas un piège. Elle sert à vérifier que vous savez prendre du recul sur vos projets et démontrer vos compétences. Vous devez montrer que vous êtes capables de :

- concevoir une architecture de données fiable ;
- intégrer, transformer et exposer des données ;
- préparer et analyser des données ;
- produire des visualisations utiles à la décision ;
- développer et comparer des modèles prédictifs ;
- identifier et mettre en œuvre un cas d'usage d'IA générative ;
- évaluer les résultats obtenus ;
- expliquer vos choix avec professionnalisme.

Ne présentez pas seulement ce que vous avez fait. Expliquez pourquoi vous l'avez fait, comment vous l'avez fait, ce que cela démontre, et quelles limites vous avez identifiées.